

机器学习代价函数总结报告

2311451 李宗杭

一、课程知识回顾

本学期机器学习课程涵盖监督学习、无监督学习、深度学习等多个领域，多种经典算法与理论

(一) 监督学习

1. 线性模型

线性回归：使用均方误差（MSE）作为损失函数，通过最小化预测值与真实值的平方差拟合线性关系，正则化可引入 L1/L2 项防止过拟合。

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (f_w(x^{(i)}) - y^{(i)})^2$$

逻辑回归：采用交叉熵损失函数，用于二分类问题，通过 sigmoid 函数将线性输出映射为概率，正则化常用 L2 范数。

$$L(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

线性判别分析（LDA）：优化目标为最大化类间散度与最小化类内散度的比值，损失函数隐含于类间与类内散度矩阵的构造中，旨在找到最优投影方向实现类别分离。

2. 非线性模型

支持向量机（SVM）：硬间隔 SVM 使用铰链损失（Hinge Loss），软间隔引入松弛变量允许部分样本出错，核技巧可处理非线性问题。

$$L(w, b) = \sum_{i=1}^m (1 - y_i(w^T x_i + b))_+ + \lambda \|w\|^2$$

神经网络：损失函数依任务而定，分类问题常用交叉熵（如 Softmax 交叉熵），回归问题用均方误差。反向传播算法（BP）通过链式求导更新参数。

3. 概率模型

朴素贝叶斯：基于极大似然估计或贝叶斯定理，损失函数隐含于对数似然项中，如多项式 NB 的损失函数包含先验概率和条件概率的对数和，拉普拉斯平滑处理零概率问题。

集成学习：AdaBoost 使用指数损失，通过迭代加权样本和弱分类器提升整体性能；Bagging 与随机森林通过自助采样和特征随机选择降低方差，损失函数依基学习器（如决策树的 Gini 指数或均方差）而定。

$$L(y, f(x)) = \sum_{i=1}^m \exp(-y_i f(x_i))$$

(二) 无监督学习

1. 聚类算法

K-means: 损失函数为簇内平方和 (WSS)，通过迭代更新簇中心最小化样本与中心的距离平方和。

$$E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

DBSCAN: 基于密度可达性划分簇，无显式损失函数，通过邻域半径 ϵ 和最小点数 MinPts 定义簇结构，旨在识别高密度区域。

2. 降维与生成模型: 主成分分析 (PCA) 通过最大化投影方差 (损失函数为原始数据与重构数据的均方差) 实现维度压缩; 生成对抗网络 (GAN) 的损失函数为对抗损失, 生成器试图最小化, 判别器最大化。

$$\mathbb{E}_{z \sim p_z} [\log(1 - D(g(z)))]$$

$$\mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(g(z)))]$$

(三) 深度学习与框架应用

卷积神经网络 (CNN): 用于图像分类, 损失函数多为交叉熵, 如 LeNet-5 使用 Softmax 交叉熵, 结合卷积层、池化层提取特征, 通过反向传播优化参数。

循环神经网络 (RNN/LSTM): 处理序列数据, 损失函数依任务而定 (如语言模型的交叉熵), 通过 BPTT (时间反向传播) 解决长依赖问题。

MindSpore 框架: 支持自动微分与分布式训练, 可定义自定义损失函数, 如课程中 LeNet-5 案例使用 SoftmaxCrossEntropyWithLogits 损失, 结合梯度下降优化器实现手写数字识别。

二、论文内容分析

(一) 核心贡献

论文对 8 种文本分类方法的损失函数进行形式化分析, 统一表示为

$$L_c = g_1(y_i \vec{x}_i \vec{\beta}) + g_2(\vec{\beta})$$

其中 g_1 为训练集损失, g_2 为复杂度惩罚 (正则化项), 具体方法包括:

SVM: 铰链损失+L2 正则

$$L_c = \sum_{i=1}^n (1 - y_i \vec{x}_i \vec{\beta})_+ + \lambda \|\vec{\beta}\|^2$$

线性回归 (LLSF): 平方损失+L2 正则, 正则化后性能超越 SVM。

$$L_c = \sum_{i=1}^n (1 - y_i \vec{x}_i \vec{\beta})^2 + \lambda \|\vec{\beta}\|^2$$

朴素贝叶斯 (NB): 无平滑时包含对数似然项与指数正则项, 拉普拉斯平滑引入额外 L1 正则项。

$$L_c = - \sum_{y_i=1} y_i \vec{x}_i \vec{\beta} + S_c \|e^{\vec{\beta}}\|_1$$

kNN: 局部线性模型, 仅考虑邻域内样本的线性损失+局部 L2 正则。

$$L_c = - \sum_{y_i=1 \wedge \vec{x}_i \in R_k(\vec{x})} y_i \vec{x}_i \vec{\beta}_x + \frac{1}{2} \|\vec{\beta}_x\|^2$$

(二) 关键结论

1. 正则化的重要性: 合理调整 λ 可平衡训练损失与模型复杂度, 如线性回归通过 L2 正则化 (岭回归) 在 Reuters-21578 数据集上取得最优宏平均 F1 值 (0.6398), 优于 SVM。

2. 损失函数形态差异: 不同方法对误分类样本的敏感度不同, 如 LLSF 对误分类样本惩罚最重 (平方损失), NNet (神经网络) 惩罚最轻 (交叉熵), SVM 通过铰链损失仅惩罚边界内的误样本。

3. 假设空间与泛化能力: NB 的正则化项与其他方法的 L2 正则不同, 反映其生成式模型的特性, 但其性能受限可能源于正则化形式与文本数据分布的不匹配。

三、代价函数分类总结

算法类型	算法名称	损失函数形式	正则化项	核心目标
监督学习-线性	线性回归	$L(w) = \frac{1}{2n} \sum_{i=1}^n (f_w(x^{(i)}) - y^{(i)})^2$	L1/L2正则	最小化预测值与真实值的平方误差, 拟合线性关系
	逻辑回归	$L(\theta) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$	L2正则	通过概率建模实现二分类, 最大化对数似然
	LDA	$\max_w \frac{(w^T(\mu_1 - \mu_2))^2}{w^T(\Sigma_1 + \Sigma_2)w}$	无	最大化类间散度/最小化类内散度, 寻找最优投影方向
监督学习-非线性	SVM	$L(w, b) = \sum_{i=1}^n \max(0, 1 - y_i(w^T x_i + b)) + \lambda w ^2$	L2正则	最小化铰链损失, 最大化分类间隔, 核技巧处理非线性
	神经网络	分类: 交叉熵; 回归: 均方差	Dropout/BatchNorm	通过多层非线性变换拟合复杂数据分布, 反向传播优化参数
概率模型	朴素贝叶斯	$L = - \sum_{y_i=1} y_i \vec{x}_i^T \vec{\beta} + S_c \ e^{\vec{\beta}}\ _1$ (无平滑)	拉普拉斯平滑 (L1)	最大化后验概率, 假设特征条件独立, 处理文本等高维稀疏数据
集成学习	AdaBoost	$L(y, f(x)) = \sum_{i=1}^n \exp(-y_i f(x_i))$	无	通过指数损失迭代加权样本与弱分类器, 提升整体分类精度
无监督学习	K-means	$E = \sum_{i=1}^k \sum_{x \in C_i} \ x - \mu_i\ ^2$	无	最小化簇内样本与中心的距离平方和, 实现聚类
深度学习	CNN/RNN	分类: $-\sum y_i \log \hat{y}_i$; 回归: $\sum (y_i - \hat{y}_i)^2$	L2/Dropout	提取层次化特征, 适应图像、序列等复杂数据模式

四、感悟与总结

(一) 损失函数的设计逻辑

1. 任务适配性: 回归问题用连续损失 (如 MSE), 分类问题用离散损失 (如交叉熵、铰链损失), 聚类用几何距离损失 (如 WSS), 损失函数需与任务目标一致。

2. 可优化性：损失函数应具备良好的数学性质（如可导、凸性），便于梯度下降等优化算法求解。例如，SVM 的铰链损失+L2 正则构成凸优化问题，可保证全局最优解；而神经网络的非凸损失函数（如交叉熵+权重衰减）需依赖启发式优化（如 Adam）避免局部极小。

3. 正则化的本质：正则化项（如 L1/L2）通过惩罚复杂模型防止过拟合，本质是引入先验知识。例如，L1 正则促进稀疏解（特征选择），L2 正则假设参数服从高斯分布，与贝叶斯先验建立联系。

（二）论文与课程的关联

1. 线性模型的潜力：论文中线性回归通过正则化超越 SVM，说明简单模型在合理调参下可具备强泛化能力，无需盲目追求复杂模型。

2. 损失函数可视化分析：课程中学习曲线、PR 曲线、ROC-AUC 等工具可辅助理解损失函数的优化效果，如通过学习曲线判断过拟合/欠拟合，调整正则化参数或数据增强策略。

3. 跨领域迁移：文本分类中的损失函数设计（如 NB 的对数似然+正则）可迁移至其他高维稀疏场景（如生物信息学、推荐系统），体现损失函数设计的通用性与领域特殊性的平衡。

五、结语

损失函数是机器学习模型的核心，其设计直接影响模型的优化方向与泛化能力。通过本学期的学习与论文研读，不仅掌握了各类经典损失函数的形式与应用，更理解了“损失函数+正则化+优化算法”的联合优化逻辑。未来需结合具体问题，灵活选择或设计损失函数，以实现更高效、鲁棒的机器学习模型。