



南開大學
Nankai University

《人工智能导论》实验报告

(2025~2026 学年第一学期)

实验名称：基于 NK-I 平台的 CIFAR-10 图像分类

姓 名：李宗杭

学 号：2311451

专 业：软件工程

2026 年 1 月 4 日

目 录

1	问题描述	2
2	模型构建	2
2.1	构建思路	2
2.2	网络层参数配置	3
2.2.1	卷积层	3
2.2.2	池化层	3
2.2.3	展平层	3
2.2.4	全连接层（隐藏层）	3
2.2.5	Dropout 层	3
2.2.6	全连接层（输出层）	4
2.3	网络参数配置	4
3	调参对比分析	4
3.1	卷积层数量的影响	4
3.2	学习率的影响	5
3.3	训练轮数的影响	5
3.4	全连接层神经元数的影响	5
3.5	综合调参结论	5
4	总结	6
5	参数与日志截图	7

1 问题描述

图像分类是计算机视觉领域的基础任务,其核心目标是让计算机自动识别图像中的目标类别。CIFAR-10 数据集作为经典的图像分类基准数据集,包含 10 个类别(飞机、汽车、鸟类等)的 60000 张 32×32 彩色图像,其中训练集 50000 张,测试集 10000 张。该数据集具有类别均衡、图像尺寸统一的特点,适合用于验证简单神经网络的特征提取与分类能力。

本次实验基于 NK-I 平台,使用其提供的任务流组件,基于 TensorFlow 框架构建一个简单的卷积神经网络(CNN),实现 CIFAR-10 数据集的图像分类。通过设计调参实验分析核心参数对模型性能的影响,记录训练趋势并完成结果评估,最终实现稳定的图像分类效果。

2 模型构建

2.1 构建思路

CNN 通过卷积操作提取图像的局部特征,经池化层降维后,通过全连接层完成类别映射,适用于图像分类任务。结合 CIFAR-10 彩色图像的复杂度,本次模型构建遵循“特征提取-降维-特征整合-分类”的逻辑:

- 特征提取: 采用 2 层卷积层(Conv2D),逐步增加卷积核数量,从底层边缘特征到高层语义特征递进提取;
- 降维: 每层卷积后搭配 ReLU 激活函数引入非线性,再通过最大池化层(MaxPooling2D)减少参数数量、抑制过拟合;
- 特征整合: 通过展平层(Flatten)将多维特征图转为一维向量,输入全连接层(Dense)整合特征;
- 分类与正则化: 输出层采用 Softmax 激活函数输出类别概率,中间加入 Dropout 层进一步抑制过拟合。




图 2.1: 任务流

2.2 网络层参数配置

仅展示主要参数，没有提到的参数均保持默认设置。

2.2.1 卷积层

3 个卷积层仅 filters 不一样（逐渐增大）。

filters	32	输出32个特征图，提取32种底层特征（边缘、色彩纹理等），适配彩色图复杂度。后续两个卷积层分别设为64和128，提取更丰富的高层特征
kernel_size	(3,3)	3×3的方形卷积核，平衡特征提取能力和计算量
strides	(1,1)	水平、垂直方向步长均为1，不跳过图像细节
padding	same	零填充，保证卷积后图像尺寸不变，避免边缘特征丢失
activation	relu	无梯度消失问题，计算高效

2.2.2 池化层

3 个池化层参数配置一致。

pool_size	(2,2)	2×2的方形池化核，经典降维选择
strides	(2,2)	水平、垂直方向步长均为2，将特征图尺寸缩小一半
padding	valid	不填充，直接对有效区域进行池化，无冗余数据

2.2.3 展平层

data_format	channels_last	匹配CIFAR-10的输入维度顺序
-------------	---------------	-------------------

2.2.4 全连接层（隐藏层）

units	512	隐藏层神经元数量，平衡拟合能力和计算量，适配CIFAR-10的复杂特征
activation	relu	高效无梯度消失问题

2.2.5 Dropout 层

rate	0.5	随机丢弃50%的神经元，平衡泛化能力和拟合能力，有效抑制CIFAR-10任务的过拟合
------	-----	--

2.2.6 全连接层（输出层）

units	10	对应CIFAR-10的10个分类，每个神经元输出对应类别的得分
activation	softmax	将得分转为0-1的概率值，所有类别概率之和为1，便于后续分类和损失计算

2.3 网络参数配置

batch_size	64	CIFAR-10复杂度更高，64是平衡训练效率和内存占用的最优选择
epoch	50	CIFAR-10比较复杂，经多次测试，发现至少训练50轮模型才能趋于收敛
loss	SparseCategoricalCrossentropy	适配CIFAR-10的整数类型标签（无需one-hot编码），计算预测概率与真实标签的误差
optimizer	Adam	自动调整学习率，收敛速度快且稳定，适配CIFAR-10的复杂任务
lr	0.001	Adam优化器的经典学习率，平衡收敛速度和稳定性
metrics	SparseCategoricalAccuracy	根据Loss 函数和输出维度自动调用对应的准确率评估方法

3 调参对比分析

为分析核心参数影响，设计控制单一变量的调参实验，参数组合如下：

实验组别	卷积层数量 (激活层和池化层一同变动)	epoch	lr	units (全连接层1)	Train Loss	Train Acc	Test Loss	Test Acc
1	2	50	0.001	128	0.3369	86.95%	1.4323	70.03%
2	3	50	0.001	128	0.2168	91.90%	1.5922	72.65%
3	3	50	0.01	128	2.3038	9.78%	2.3035	10.00%
4	3	50	0.0001	128	0.6416	77.76%	0.7964	72.45%
5	3	100	0.001	128	0.1252	95.56%	2.2559	72.87%
6	3	50	0.001	512	0.1075	96.43%	1.8179	73.10%

3.1 卷积层数量的影响

实验组别	卷积层数量	Train Loss	Train Acc	Test Loss	Test Acc
1	2	0.3369	86.95%	1.4323	70.03%
2	3	0.2168	91.90%	1.5922	72.65%

对比实验组 1 和组 2 的数据，可以看出在卷积层数量从 2 增加到 3 后，训练集拟合能力显著提升（训练损失降低、训练准确率提高），说明 3 层卷积能提取更丰富的图像特征；但测试集损失略有上升（过拟合轻微加剧），不过测试准确率仍提升了 2.62%，整体而言 3 层卷积的特征提取能力优于 2 层，是更优选择。

3.2 学习率的影响

实验组别	lr	Train Loss	Train Acc	Test Loss	Test Acc
2	0.001	0.2168	91.90%	1.5922	72.65%
3	0.01	2.3038	9.78%	2.3035	10.00%
4	0.0001	0.6416	77.76%	0.7964	72.45%

对比实验组 2、3、4 的数据，可以看出，若学习率过大 (0.01)，则模型完全无法收敛（训练准确率仅 9.78%，接近随机猜测），参数更新幅度过大导致震荡；而学习率过小 (0.0001)，则训练集拟合能力不足（训练准确率仅 77.76%），收敛速度极慢，虽测试损失较低，但整体性能差；当学习率为 0.001 时，训练集拟合较好、测试准确率最高，是当前实验的最优学习率。

3.3 训练轮数的影响

实验组别	epoch	Train Loss	Train Acc	Test Loss	Test Acc
2	50	0.2168	91.90%	1.5922	72.65%
5	100	0.1252	95.56%	2.2559	72.87%

对比实验组 2 和 5 的数据，可以看出增加训练轮数 (50 -> 100) 后，训练集拟合能力进一步提升，但测试损失大幅上升、测试准确率仅微涨 0.22%，说明模型已出现严重过拟合，过度记忆训练集细节，泛化能力下降。因此，50 轮是更合理的训练轮数，无需增加至 100 轮。

3.4 全连接层神经元数的影响

实验组别	units	Train Loss	Train Acc	Test Loss	Test Acc
2	128	0.2168	91.90%	1.5922	72.65%
6	512	0.1075	96.43%	1.8179	73.10%

对比实验组 2 和 6 的数据，可以看出增加全连接层神经元数 (128 -> 512) 后，训练集拟合能力显著增强，但测试损失上升、测试准确率仅微涨 0.45%，说明模型过拟合加剧。因此，128 个神经元已足够支撑特征整合，增加至 512 对测试集性能提升有限，反而会增加计算成本。

3.5 综合调参结论

当前实验关键参数的最优组合为：

- 卷积层数量：3 层
- 训练轮数：50

- 学习率: 0.001
- 全连接层 1 神经元数: 128

此组合下, 模型在训练集拟合充分的同时, 测试准确率达 72.65%, 过拟合程度相对可控, 是兼顾性能与效率的最优选择。

4 总结

本实验基于 NK-I 平台和 TensorFlow 框架, 成功构建了适用于 CIFAR-10 数据集的卷积神经网络, 通过控制单一变量的调参实验, 明确了卷积层数量、训练轮数、学习率与神经元数等核心参数对模型性能的影响, 最终实现了 72.65% 的测试准确率。实验过程中完整记录了模型构建流程、参数配置、训练趋势及调参结果, 验证了 CNN 在图像分类任务中的有效性。本次实验不仅掌握了神经网络的构建与调参方法, 也加深了对深度学习模型训练原理的理解。

5 参数与日志截图

参数设置

filters

32

kernel_size

(3,3)

strides

(1,1)

padding

same

activation

relu

图 5.2: 卷积层参数配置

参数设置

pool_size

(2, 2)

strides

None

padding

valid

图 5.3: 池化层参数配置

参数设置

data_format

channels_last

input_shape

None

图 5.4: 展平层参数配置

参数设置

units

activation

relu

图 5.5: 全连接层 1 参数配置

参数设置

rate

图 5.6: Dropout 层参数配置

参数设置

units

activation

softmax

图 5.7: 全连接层 2 参数配置

网络配置

batch_size:

epoch:

loss:

sparse_categorical_crossentropy

optimizer:

Adam

lr:

metrics:

accuracy

取消 确定

图 5.8: 网络参数配置

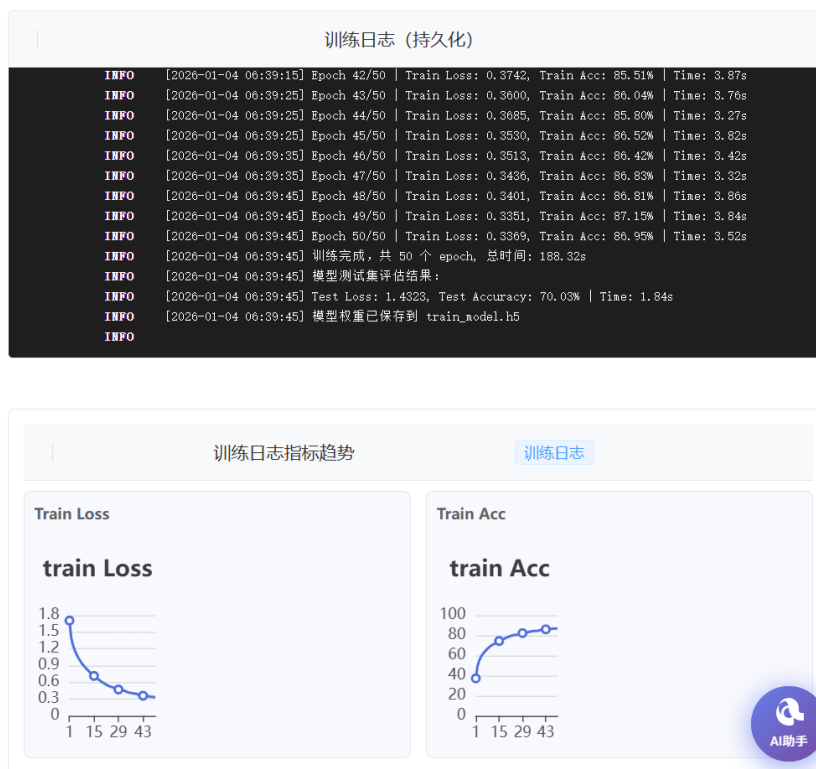


图 5.9: 实验组 1

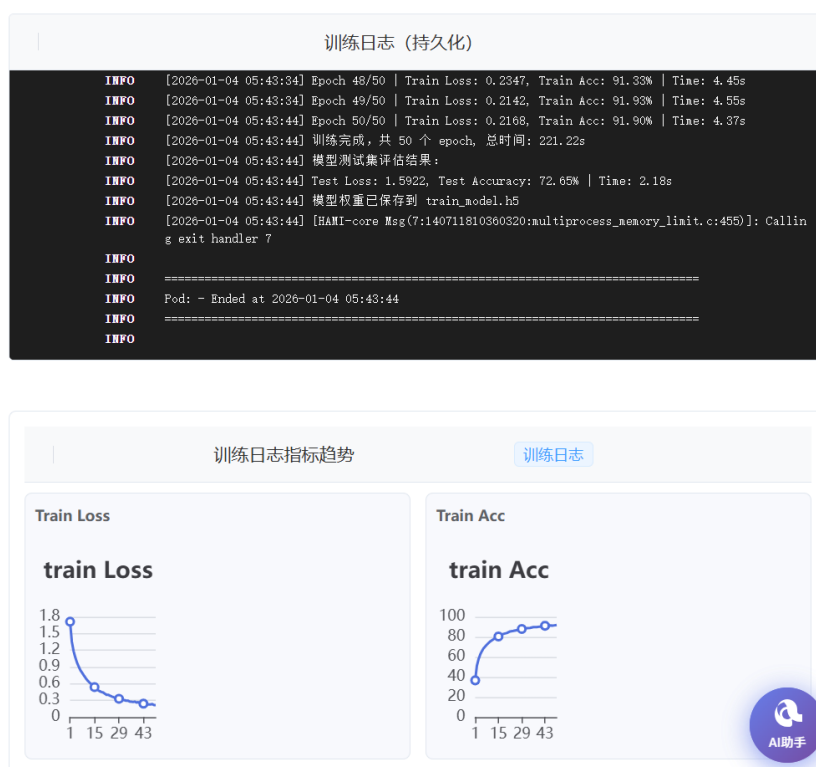


图 5.10: 实验组 2

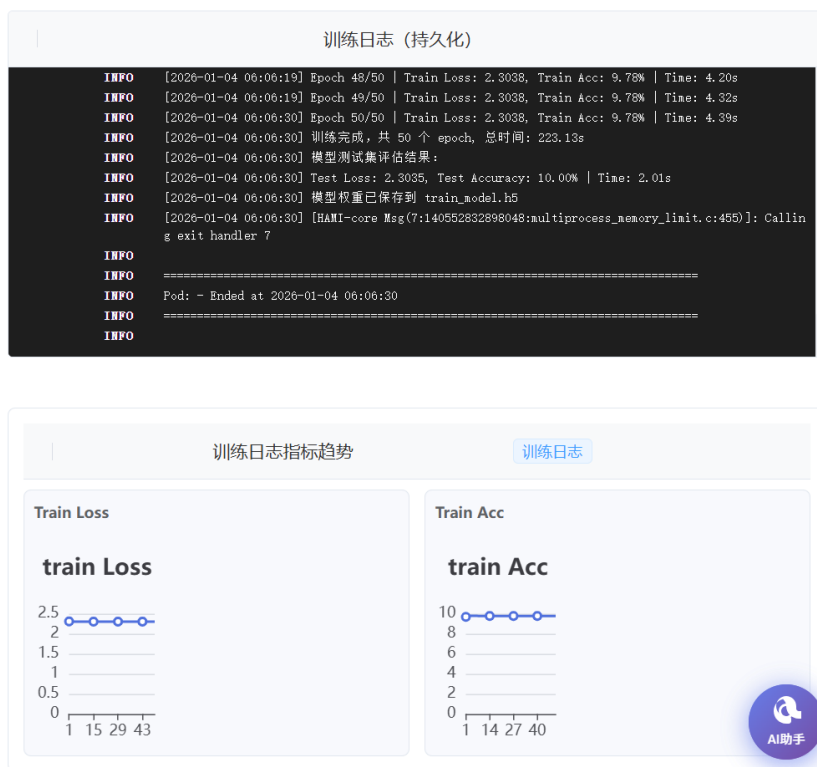


图 5.11: 实验组 3

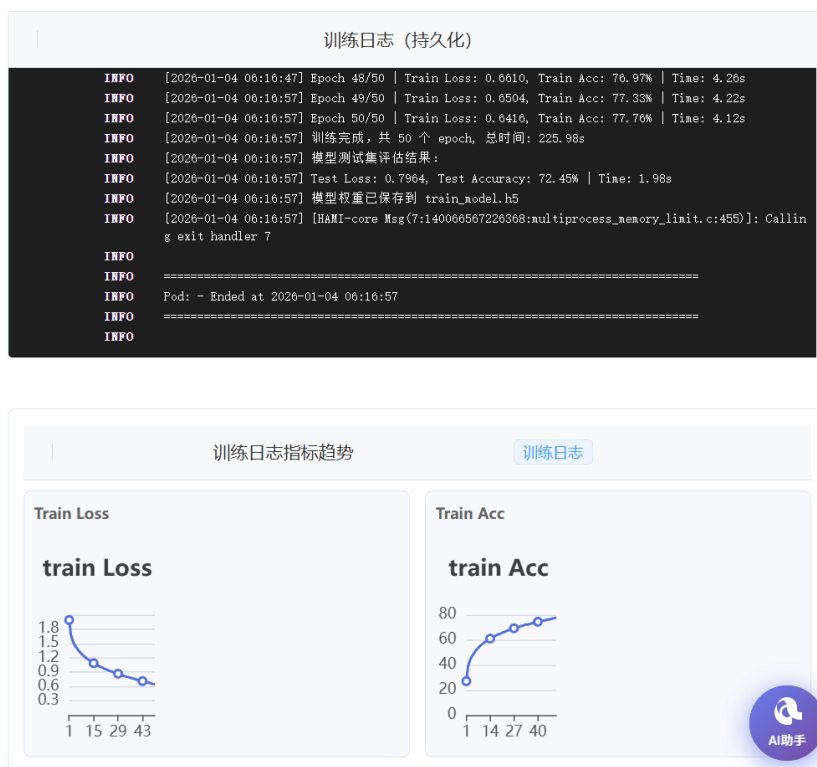


图 5.12: 实验组 4

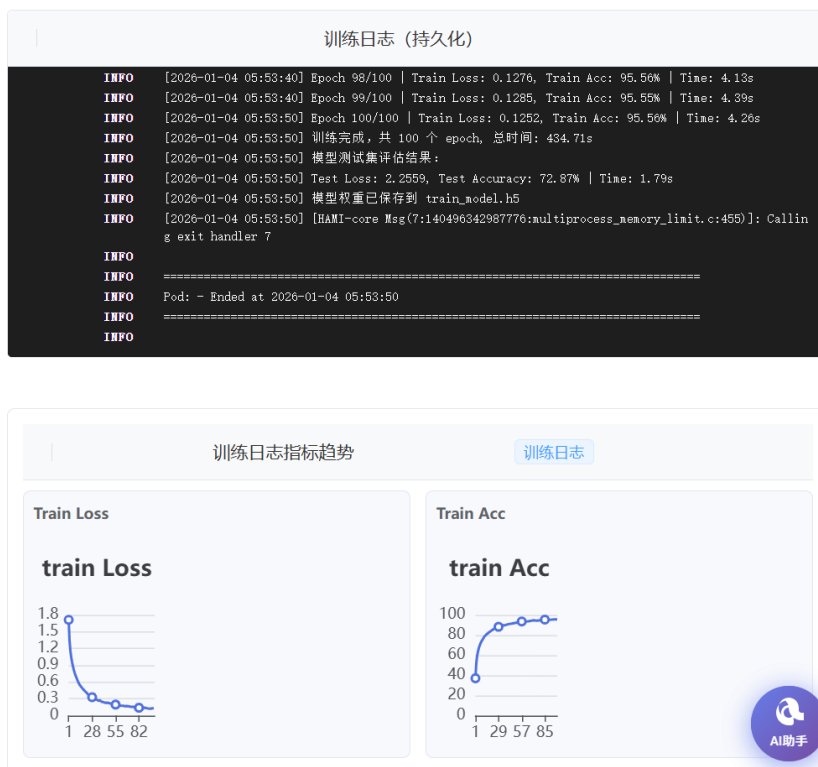


图 5.13: 实验组 5

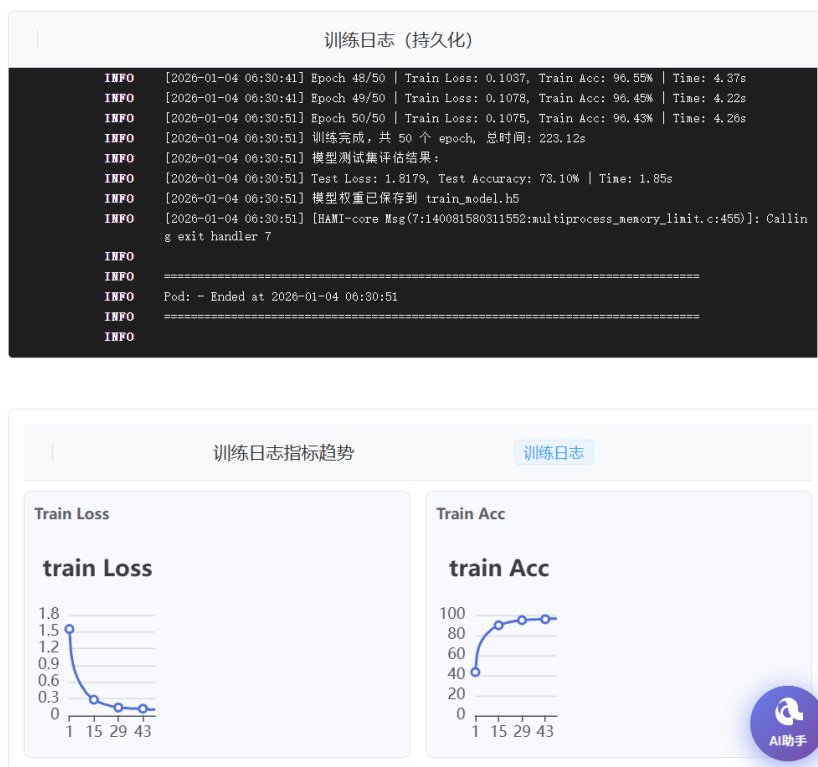


图 5.14: 实验组 6