

LLM 大模型配置-硅基流动

硅基流动网址：<https://cloud.siliconflow.cn/models>

注意：本案例基于苍穹 V7.0.8 版本编制，其他版本请参考金蝶云社区。

1. 简介

硅基流动（SiliconCloud、SiliconFlow）是硅基流动公司推出的一站式大模型云服务平台，致力于为开发者和企业提供高效、低成本且全面的生成式人工智能（GenAI）模型服务，包括 IaaS、PaaS 和 MaaS。其核心目标是通过优化大模型使用体验，帮助用户实现“Token 自由”，即以更低成本和更高效率使用先进的大语言模型（LLMs）及其他生成式人工智能（AI）模型。

AI Agent 平台支持两种服务配置方式：**公有云** 和 **私有化部署**。本文将详细介绍如何利用硅基流动配置大模型，本文以配置 DeepSeek 模型为例，以帮助开发者轻松完成大模型的部署和使用，除此之外，开发者还可以选择硅基流动其他支持的模型，配置方法是一样的。

2. 大模型配置

2.1 适用范围

DeepSeek 的官方及第三方模型 API 服务支持以下模型版本：

- **DeepSeek 对话模型**（已更新至 V3）
- **DeepSeek 推理模型**（已更新至 R1）

支持的云服务供应商包括但不限于：

- DeepSeek 官方
- 硅基流动
- 火山方舟

这些服务可在 **AI 能力中心** 应用中配置后直接使用。

在硅基流动中，能够支持的所有模型如图：

Body

application/json

LLM VLM

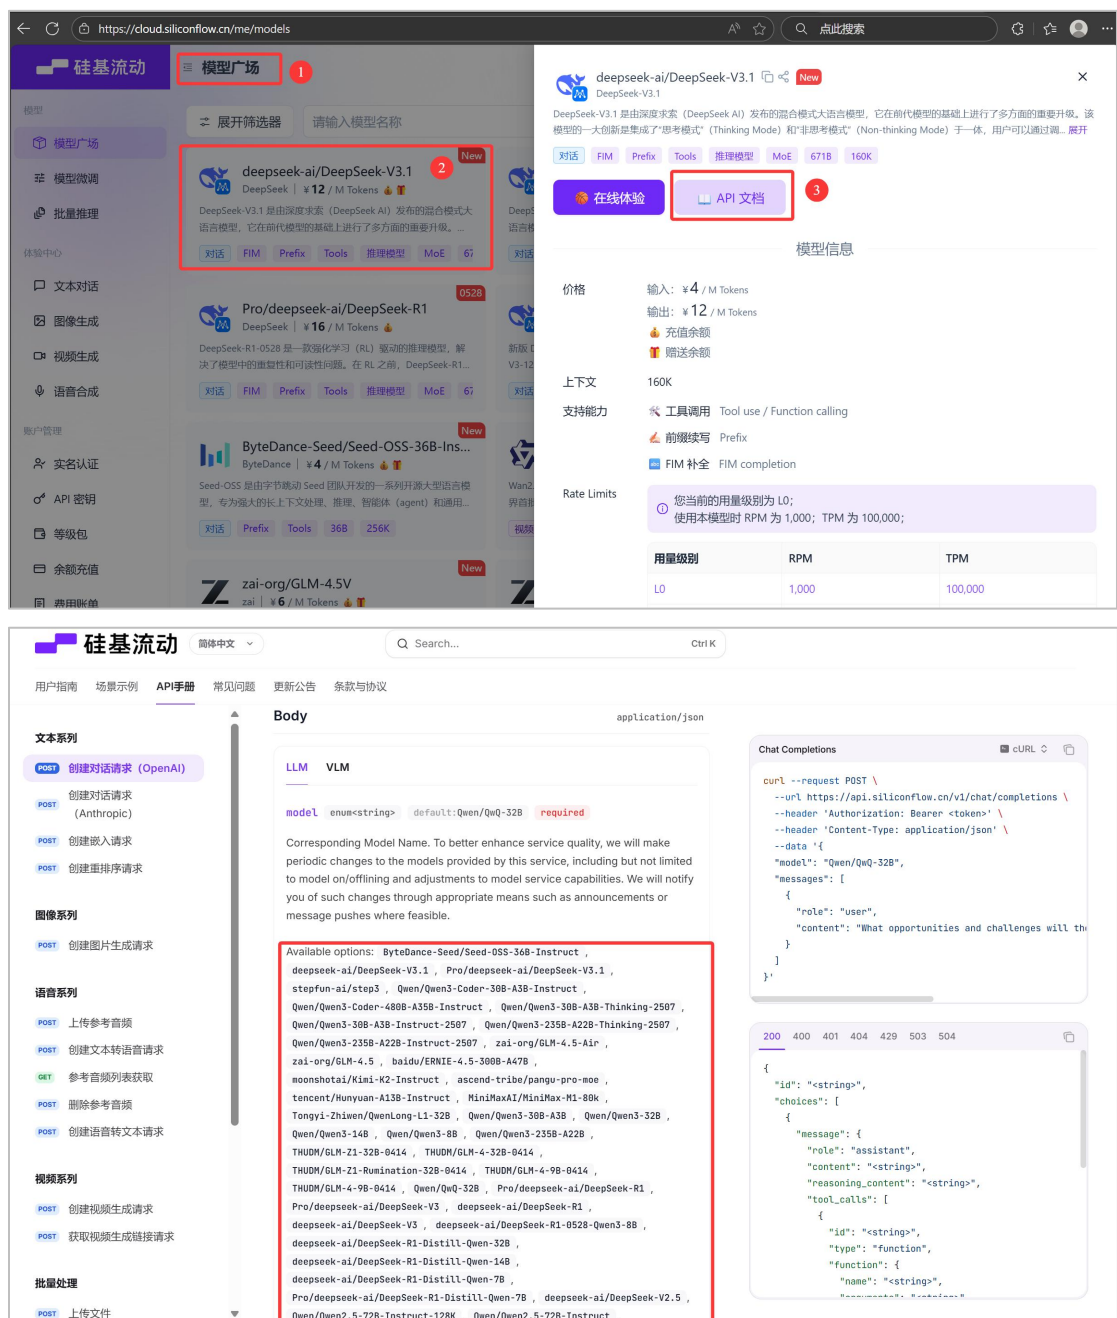
model enum<string> default:Qwen/QwQ-32B **required**

Corresponding Model Name. To better enhance service quality, we will make periodic changes to the models provided by this service, including but not limited to model on/offlining and adjustments to model service capabilities. We will notify you of such changes through appropriate means such as announcements or message pushes where feasible.

Available options: ByteDance-Seed/Seed-05S-36B-Instruct ,
deepseek-ai/DeepSeek-V3.1 , Pro/deepseek-ai/DeepSeek-V3.1 ,
stepfun-ai/step3 , Qwen/Qwen3-Coder-30B-A3B-Instruct ,
Qwen/Qwen3-Coder-480B-A35B-Instruct , Qwen/Qwen3-30B-A3B-Thinking-2507 ,
Qwen/Qwen3-30B-A3B-Instruct-2507 , Qwen/Qwen3-235B-A22B-Thinking-2507 ,
Qwen/Qwen3-235B-A22B-Instruct-2507 , zai-org/GLM-4.5-Air ,
zai-org/GLM-4.5 , baidu/ERNIE-4.5-300B-A47B ,
moonshotai/Kimi-K2-Instruct , ascend-tribe/pangu-pro-moe ,
tencent/Hunyuan-A13B-Instruct , MiniMaxAI/MiniMax-M1-80k ,
Tongyi-Zhiwen/QwenLong-L1-32B , Qwen/Qwen3-30B-A3B , Qwen/Qwen3-32B ,
Qwen/Qwen3-14B , Qwen/Qwen3-8B , Qwen/Qwen3-235B-A22B ,
THUDM/GLM-Z1-32B-0414 , THUDM/GLM-4-32B-0414 ,
THUDM/GLM-Z1-Rumination-32B-0414 , THUDM/GLM-4-9B-0414 ,
THUDM/GLM-4-9B-0414 , Qwen/QwQ-32B , Pro/deepseek-ai/DeepSeek-R1
Pro/deepseek-ai/DeepSeek-V3 , deepseek-ai/DeepSeek-R1 ,
deepseek-ai/DeepSeek-V3 , deepseek-ai/DeepSeek-R1-0528-Qwen3-8B ,
deepseek-ai/DeepSeek-R1-Distill-Qwen-32B ,
deepseek-ai/DeepSeek-R1-Distill-Qwen-14B ,
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B ,
Pro/deepseek-ai/DeepSeek-R1-Distill-Qwen-7B , deepseek-ai/DeepSeek-V2.5 ,
Qwen/Qwen2.5-72B-Instruct-128K , Qwen/Qwen2.5-72B-Instruct ,
Qwen/Qwen2.5-32B-Instruct , Qwen/Qwen2.5-14B-Instruct ,
Qwen/Qwen2.5-7B-Instruct , Qwen/Qwen2.5-Coder-32B-Instruct ,
Qwen/Qwen2.5-Coder-7B-Instruct , Qwen/Qwen2-7B-Instruct ,
TeleAI/TeleChat2 , THUDM/glm-4-9b-chat ,
Vendor-A/Qwen/Qwen2.5-72B-Instruct , internlm/internlm2_5-7b-chat ,
Pro/Qwen/Qwen2.5-7B-Instruct , Pro/Qwen/Qwen2-7B-Instruct ,
Pro/THUDM/glm-4-9b-chat

Example: "Qwen/QwQ-32B"

查看路径：【模型广场】-【选择具体模型】-【API 文档】



其中框住的就是 DeepSeek 系列的模型，同时还包括 Qwen、THUDM 等模型的配置。同时这些选项也是在苍穹算法中心中配置模型的关键参数。

注：THUDM 是清华大学数据挖掘与知识管理研究小组。


2.2 操作步骤

2.2.1 获取模型名称、API KEY 和 URL 地址


登录硅基流动：[硅基流动用户系统](#)，统一登录 SSO



进入首页：



在右侧菜单栏中单击“API 密钥”：



若首次访问未创建秘钥，需要单击“新建 API 秘钥”。

API 密钥是您访问 SiliconCloud 接口的凭证，具有该账户的完整权限，请您妥善保管。

2.2.2 回到模型广场，随便点击一个模型，在弹出的伸缩框中点击“API 文档”，进入 API 文档页面。

这里以“Pro/deepseek-ai/DeepSeek-V3”为例。



根据 API 文档，获取以下信息（模型名称枚举值、URL 地址、API Key）：

（1）模型名称枚举值

即“model”中的“Available Options”各个枚举值，如“Pro/deepseek-ai/DeepSeek-R1”，“Pro/deepseek-ai/DeepSeek-V3”，“deepseek-ai/DeepSeek-V3”，本次教程我们使用“Pro/deepseek-ai/DeepSeek-V3”进行配置（建议直接配置“deepseek-ai/DeepSeek-V3”，配置其他可能会出现余额不足的问题，充它五块钱就好）

内容如下：

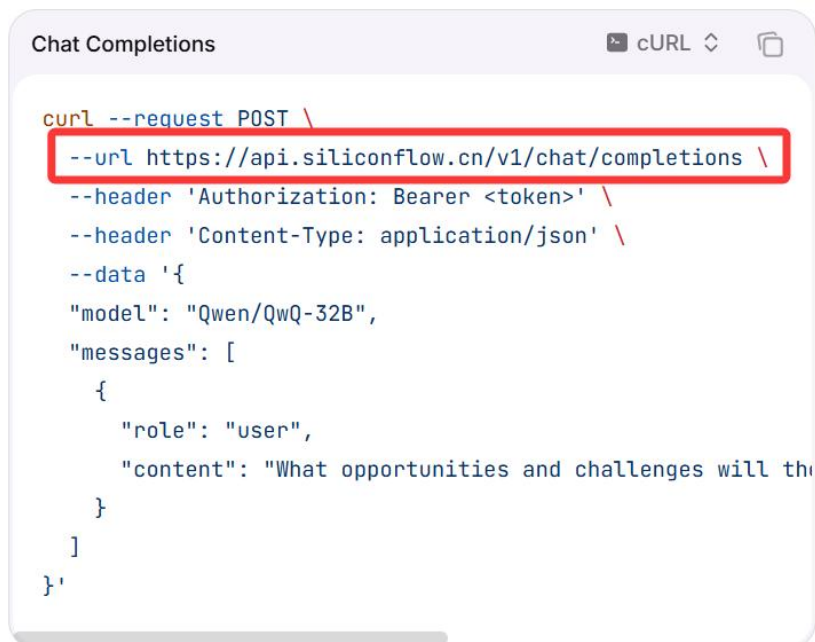
Available options:

ByteDance-Seed/Seed-05S-36B-Instruct,
deepseek-ai/DeepSeek-V3.1,
Pro/deepseek-ai/DeepSeek-V3.1,
stepfun-ai/step3,
Qwen/Qwen3-Coder-30B-A3B-Instruct,
Qwen/Qwen3-Coder-480B-A35B-Instruct,
Qwen/Qwen3-30B-A3B-Thinking-2507,
Qwen/Qwen3-30B-A3B-Instruct-2507,
Qwen/Qwen3-235B-A22B-Thinking-2507,
Qwen/Qwen3-235B-A22B-Instruct-2507,
zai-org/GLM-4.5-Air,
zai-org/GLM-4.5,
baidu/ERNIE-4.5-300B-A47B,
moonshotai/Kimi-K2-Instruct,
ascend-tribe/pangu-pro-moe,
tencent/Hunyuan-A13B-Instruct,
MiniMaxAI/MiniMax-M1-80k,
Tongyi-Zhiwen/QwenLong-L1-32B,
Qwen/Qwen3-30B-A3B,
Qwen/Qwen3-32B,
Qwen/Qwen3-14B,
Qwen/Qwen3-8B,
Qwen/Qwen3-235B-A22B,
THUDM/GLM-Z1-32B-0414,
THUDM/GLM-4-32B-0414,
THUDM/GLM-Z1-Rumination-32B-0414,
THUDM/GLM-4-9B-0414,
THUDM/GLM-4-9B-0414,
Qwen/QwQ-32B,
Pro/deepseek-ai/DeepSeek-R1,
Pro/deepseek-ai/DeepSeek-V3,
deepseek-ai/DeepSeek-R1,
deepseek-ai/DeepSeek-V3,
deepseek-ai/DeepSeek-R1-0528-Qwen3-8B,
deepseek-ai/DeepSeek-R1-Distill-Qwen-32B,
deepseek-ai/DeepSeek-R1-Distill-Qwen-14B,
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B,
Pro/deepseek-ai/DeepSeek-R1-Distill-Qwen-7B,
deepseek-ai/DeepSeek-V2.5,
Qwen/Qwen2.5-72B-Instruct-128K,
Qwen/Qwen2.5-72B-Instruct,
Qwen/Qwen2.5-32B-Instruct,
Qwen/Qwen2.5-14B-Instruct,
Qwen/Qwen2.5-7B-Instruct,


```
Qwen/Qwen2.5-Coder-32B-Instruct,  
Qwen/Qwen2.5-Coder-7B-Instruct,  
Qwen/Qwen2-7B-Instruct,  
TeleAI/TeleChat2,  
THUDM/glm-4-9b-chat,  
Vendor-A/Qwen/Qwen2.5-72B-Instruct,  
internlm/internlm2_5-7b-chat,  
Pro/Qwen/Qwen2.5-7B-Instruct,  
Pro/Qwen/Qwen2-7B-Instruct,  
Pro/THUDM/glm-4-9b-chat
```

(2) URL 地址

在右方板块的 curl 区域查看。



```
Chat Completions  cURL  📄  
  
curl --request POST \  
--url https://api.siliconflow.cn/v1/chat/completions \  
--header 'Authorization: Bearer <token>' \  
--header 'Content-Type: application/json' \  
--data '{  
  "model": "Qwen/QwQ-32B",  
  "messages": [  
    {  
      "role": "user",  
      "content": "What opportunities and challenges will the  
    }  
  ]  
'
```

(3) API Key

复制保存好的 API Key。

API 密钥

周年回馈：企业/学生认证后，即可领取专属赠金！

新建 API 密钥

API密钥 是您访问 SiliconCloud 接口的凭证，具有该账户的完整权限，请您妥善保管。

密钥(点击复制)	描述	创建时间	操作
sk-w*****coyh	学习使用	2025-03-03 20:07:15	删除 编辑

< 1 >

注：请保证硅基流动账号内有余额，否则无法使用模型！

硅基流动

余额充值

模型

模型广场

模型微调

批量推理

体验中心

文本对话

图像生成

视频生成

语音合成

账户管理

实名认证

API 密钥

等级包

余额充值

费用账单

文档中心

工单反馈

商务合作

余额

总余额

余额预警已开启 (去设置)

22.0044元

充值余额

8.8516元

赠送余额

13.1527元

赠金兑换

请输入 SiliconFlow Pass 兑换码

立即兑换

在线充值

支付金额:

10元

50元

100元

1000元

2000元

5000元

10000元

其它金额

支付方式:

微信

确认支付


我已知悉充值资金不支持直接开具发票，确认支付即代表同意本平台「充值协议」

对公转账

提示: 请先完成 [企业实名认证](#)，通过后可进行对公打款。

3. 配置算法服务

打开 AI 服务云 → AI 能力中心 → 算法服务，点击“新增”按钮。



(1) 填写算法服务配置表单：

属性	值
服务编码	自动生成
服务名称	自定义填写。如：Pro/deepseek-ai/DeepSeek-V3
分组	可以选择自定义分组，若无，先创建分组
是否支持流式	打开此开关。
模型类型	选择 LLM（大语言模型）
基础大模型	根据需要，选择“DeepSeek-V3”（对话模型）或者“DeepSeek-R1”（推理模型）
可选模型	Pro/deepseek-ai/DeepSeek-V3（7.0.1 版本没有，可以参考 7.0.1 的配置）

配置界面如下：

保存退出

基本信息

服务编码*

Algo_随机码

服务名称*

Pro/deepseek-ai/DeepSeek-V3

服务版本号

分组

自定义分组

创建人

张三

上架时间

2025-09-08 18:11:47

算法服务说明

是否支持流式

类型选择

模型类型

LLM

基础大模型

DeepSeek-V3

限流配置

队列长度

200

任务等待时间 (单位s)

10

可选配置

model

Pro/deepseek-ai/DeepSeek-V3

保存并点击「审核」和「启用」按钮，将状态设置为「已审核」和「可用」。

算法服务列表常用条件过滤

搜索编码/名称展开过滤

新增删除审核禁用刷新退出设置助手中控模型

搜索名称

已选1条，共3条

全部

视觉识别服务

对话机器人平台

AI开发平台

自定义分组

#	服务编码	服务名称	版本号	创建人	算法服务说明	使用状态	请求参数示例	返回结果参数示例
1	Algo_CB1962B2	Pro/deepseek-ai/DeepSeek-V3		张三		可用		已
2	BAIDU_EMBEDDING_V1	BAIDU_ERNIE_BOT		张三		可用		已
3	KINGDEE_EMBEDDING_NEW	BAAI/BGE-M3-Embedding				可用		已

4. 配置服务实例

打开 AI 服务云 → AI 能力中心 → 服务实例，点击“新增”按钮。

填写服务实例表单：

属性	值
实例编码	自动生成
实例名称	填写你的实例名称，可自定义，如 Pro/deepseek-ai/DeepSeek-V3
所属服务	选择你已经配置好的算法服务
并发控制策略	QPS(Queries Per Second, 每秒处理的“查询 / 请求” 数量)

	RPM(Requests Per Minute,每分钟处理的“请求”数量)
最大并发数	根据需要控制，输入对应数字，如：5
认证方式	选择“TOKEN 认证”
client ID	填写模型名称枚举值（如 Pro/deepseek-ai/DeepSeek-V3）
secret key	填写您的 API Key
协议类型	填写 URL 地址中的协议类型（通常是 https）
主机	填写 URL 地址中的主机部分（如 api.siliconflow.cn）
端口号	填写 URL 地址中的端口号（通常是 443）
上下文地址	填写 /v1/chat/completions

配置界面如下：

▼ 基本信息

实例编码*

Ent_823CAC5C

实例名称*

Pro/deepseek-ai/DeepSeek-V3

所属服务*

Pro/deepseek-ai/DeepSeek-V3

并发控制策略*

QPS

最大并发数*

1

创建人

张三

▼ 配置信息

认证方式*

TOKEN认证

ClientID

SecretKey

代理用户密钥

协议类型*

HTTPS

主机*

api.siliconflow.cn

端口*

443

上下文地址

/v1/chat/completions

保存并点击「审核」和「启用」按钮，将状态设置为「已审核」和「可用」。

保存

退出

▼ 基本信息

实例编码*

Ent_随机码

实例名称*

Pro/deepseek-ai/DeepSeek-V3

所属服务*

Pro/deepseek-ai/DeepSeek-V3

并发控制策略*

QPS

最大并发数*

1

创建人

杨名

▼ 配置信息

认证方式*

TOKEN认证

ClientID

SecretKey

代理用户密钥

协议类型*

HTTPS

主机*

api.siliconflow.cn

端口*

443

上下文地址

/v1/chat/completions

服务实例列表

常用条件过滤

Q 搜索编码/名称

展开过滤

新增

删除

审核

禁用

刷新

退出

已全选1条

✓	#	实例编码	实例名称	最大并发数	创建人	所属服务	认证方式	协议类型	主机	端口	上下文地址
✓	1	Ent_823CAC5C	Pro/deepseek-ai/DeepSeek-V3	1	杨名	Pro/deepseek-ai/DeepSeek-V3	TOKEN认证	HTTPS	api.siliconflow.cn	443	/v1/chat/comp

5. 查看大模型配置是否生效

打开 AI 服务云 → AI 开发平台 → 提示词——新增



在“语言模型”下拉框中选择已配置的模型。



模型风格可以根据需要选择创意、平衡和精准。

在提示词中输入如下内容：

请将用户输入的内容翻译成英文。



然后进行测试，如下图所示，表示正常。



如果模型状态仍为“未配置”，请检查以下内容：

- 算法服务的编码是否正确。
- 算法服务及服务实例是否为“可用”状态。

同时还可以在“运营管理”下查看“会话日志”



6. 常见问题

6.1 遇到反馈大模型余额不足的问题

请自行登录“硅基流动”充值。

6.2 提示词界面编码锁定且为空

如果在 **提示词** 界面中，编码锁定且为空，或者测试时一直在转圈，请检查以下内容：

- 确保算法服务和实例已正确配置并启用。
- 检查服务实例的认证信息是否正确。

6.3 配置完成后无法选择实例

如果在 **提示词** 界面中无法选择已配置的实例，请检查以下内容：

- 确保服务实例已启用。
- 如果问题仍未解决，可以尝试在后台 `t_aicc_service` 表中将对应数据行的 `fmodeltype` 刷入 LLM 值。

6.4 版本支持

- **苍穹 6.0.15 及以上版本** 支持 DeepSeek 模型配置。
- 如果使用的是星空旗舰版，请确保版本符合要求。

扩展：并发控制策略

QPS (Queries Per Second) 和 RPM (Requests Per Minute) 都是用于衡量系统并发处理能力的指标，但它们在时间单位和应用场景上有所区别：

时间单位

QPS：指每秒处理的查询请求数，强调的是每秒的处理能力，时间单位是秒。例如，一个系统的 QPS 为 100，表示该系统每秒能够处理 100 个查询请求。

RPM：是每分钟处理的请求数，时间单位是分钟。如果一个系统的 RPM 为 6000，意味着该系统每分钟能够处理 6000 个请求，换算成 QPS 约为 100 ($6000 \div 60 = 100$)。

应用场景

QPS：通常用于衡量对实时性要求较高的系统，如数据库查询、搜索引擎等。在这些场景下，每秒的处理速度对于系统的性能和响应时间至关重要。例如，在高并发的电商搜索场景中，需要快速响应用户的搜索请求，QPS 是评估搜索系统性能的关键指标。

RPM：更多地用于一些对时间间隔要求相对宽松，或者以分钟为单位来统计和分析业务量的场景。例如，在统计网站的访问量、批处理任务的执行频率等方面，RPM 可以更直观地反映出在一段时间内的请求处理情况。比如，统计某网站在某一小时内每一分钟的访问请求数，用 RPM 就比较合适。

总的来说，QPS 更侧重于实时性和短时间内的精确性能衡量，而 RPM 则在一些更关注较长时间周期内的业务量统计和分析的场景中使用得更为广泛。两者可以根据具体的业务需求和系统特点来选择使用，以更好地评估和优化系统的并发处理能力。