

Embedding 模型配置-硅基流动

1. 简介

Embedding 是一种将高维数据（如文本、图像等）转换为低维向量的技术。这些向量能够捕捉数据的内在结构和语义信息，使计算机能够更高效地处理和理解数据。主要用途如下表所示：

用途	说明
自然语言处理（NLP）	将单词或句子转换为向量，使其能够被机器学习模型处理。常用于文本分类、情感分析、机器翻译等任务。
图像处理	将图像转换为向量，用于图像分类、相似性匹配等
推荐系统	将用户或物品特征转换为向量，用于计算相似性，提供个性化推荐。

优点：


- 捕捉语义信息：向量能够反映数据的内在含义。
- 降低维度：将高维数据映射到低维空间，便于处理。
- 提升模型性能：为机器学习和深度学习模型提供更有效的输入。

常见的 Embedding 模型

- Word2Vec：用于文本数据。
- GloVe：用于文本数据。
- BERT：用于文本数据。
- BAAI/bge-m3：用于文本数据（如文档中提到的模型）。

本次我们就用到的是 BAAI/bge-m3。





2. 新建算法服务

在【AI 服务云】—【AI 能力中心】中—新增【算法服务】（7.0.8 已经自带了这个服务编码，需要【反审核】进行编辑，7.0.1 的话就自己新建一个即可）。



算法服务列表							
常用条件过滤							
新增	删除	审核	禁用	刷新	退出	设置助手中控模型	
搜索名称							
已选1条, 共16条							
#	服务编码	服务名称	版本号	创建人	算法服务说明	使用状态	
☐	2	Algo_873F76E3	Pro/deepseek-ai/DeepSeek-V3	钟伟纯		可用	
☐	3	Algo_8D93250A	BAAI/BGE-Reranker-V2-M3			可用	
☐	4	AWS_ANTHROPIC_CLAUDE_MESSAGES	亚马逊AnthropicClaudeMessages		本算法服务对接的是亚马逊Amazon Bedrock API Reference接口, 非流接口: Amazon Bedrock ...	可用	
☐	5	AZURE_EMBEDDING_ADA_002	Azure text embedding ada 002	administrator		可用	
☐	6	AZURE_GPT_35	Azure OpenAI Service: gpt-3.5	administrator		可用	
☐	7	AZURE_GPT_35_16	Azure OpenAI Service: gpt-3.5-16k	administrator		可用	
☐	8	AZURE_GPT_40	Azure OpenAI Service: gpt-4.0	administrator		可用	
☐	9	AZURE_GPT_40_32	Azure OpenAI Service: gpt-4.0-32k	administrator		可用	
☐	10	BAIDU_ERNIE_BOT	百度: 文心一言	administrator		可用	
☐	11	DOUBAO_PRO_128K	豆包 pro 128k			可用	
☐	12	DOUBAO_PRO_32K	豆包 pro 32k			可用	
☐	13	DOUBAO_PRO_4K	豆包 pro 4k			可用	
☐	14	KINGDEE_CODE_GPT	金蝶: 代码生成大模型	administrator		可用	
☒	15	KINGDEE_EMBEDDING_NEW	BAAI/bge-m3			禁用	

- 服务编码: 必须填写 KINGDEE_EMBEDDING_NEW。
- 服务名称: 可以自定义, 如 BAAI/BGE-M3-Embedding。
- 可选配置中的 model 字段: 必须填写 BAAI/bge-m3。
- 其他字段: 无需填写。

将该算法【审核】, 变成【启用】可用状态。

基本信息

服务编码*
KINGDEE_EMBEDDING_NEW

分组
自定义分组

算法服务说明
-

服务名称*
BAAI/BGE-M3-Embedding

创建人
-

是否支持流式
☒

服务版本号
-

上架时间
2025-02-28 00:00:00

类型选择

模型类型
基础大模型

限流配置

队列长度
200

任务等待时间 (单位s)
10

可选配置

model
BAAI/bge-m3

算法服务列表

常用条件过滤

搜索编码/名称

展开过滤

新增 删除 审核 禁用 刷新 退出 设置助手中控模型

搜索名称

已选1条, 共3条

全部

视觉识别服务

对话机器人平台

AI开发平台

自定义分组

#	服务编码	服务名称	版本号	创建人	算法服务说明	使用状态	请求参数示例	返回结果参数示例
☐	1	Algo_CB1962B2	Pro/deepseek-ai/DeepSeek-V3	张三		可用		已
☐	2	BAIDU_EMBEDDING_V1	BAIDU_ERNIE_BOT	张三		可用		已
☒	3	KINGDEE_EMBEDDING_NEW	BAAI/BGE-M3-Embedding			可用		已

3. 新建服务实例

在【AI 服务云】—【AI 能力中心】中—新增【服务实例】

保存 退出

基本信息

实例编码*
Ent_随机码

并发控制策略*
QPS

实例名称*
EMBEDDING-BAAI/bge-m3

最大并发数*
5

所属服务*
BAAI/BGE-M3-Embedding

创建人
张三

配置信息

认证方式*
TOKEN认证

代理用户密钥

端口*
443

ClientID

协议类型*
HTTPS

上下文地址
/v1/embeddings

SecretKey
.....

主机*
api.siliconflow.cn

- **编码：**自动生成即可。
- **实例名称：**自定义即可。如： EMBEDDING-BAAI/bge-m3
- **所属服务字段：**选出刚才新建的算法。
- **认证方法：**选择 token。
- **Clientid：**置空。
- **SecretKey：**填写硅基流动中的 API Key
- **主机：**填写 URL 地址中的主机部分（如 api.siliconflow.cn）。
- **端口号：**填写 URL 地址中的端口号（通常是 443）。
- **上下文地址：**填写 /v1/embeddings。
- **其他字段：**按照上图填写即可。

将服务实例进行【审核】，变成【启动】可用状态。（记得先关闭算法服务页面，否则无法审核）

服务实例列表

常用条件过滤

新增

删除

审核

禁用

刷新

退出

启用

搜索编码/名称

展开过滤

已选1条，共4条

#	实例编码	实例名称	最大并发数	创建人	所属服务	认证方式	协议类型	主机	端口	上下文地址	
☐	1	BAIDU_EMBEDDING_V1	baiduembedding	5	张三	BAIDU_ERNIE_BOT	BAIDU	HTTPS	aip.baidubce.com	443	/rpc/2.0/ai_custom/
☒	2	Ent_338C2F10	EMBEDDING-BAAI/bge-m3	5	张三	BAAI/BGE-M3-Embedding	TOKEN认证	HTTPS	api.siliconflow.cn	443	/v1/embeddings
☐	3	Ent_823CAC5C	Pro/deepseek-ai/DeepSeek-V3	1	张三	Pro/deepseek-ai/DeepSeek-V3	TOKEN认证	HTTPS	api.siliconflow.cn	443	/v1/chat/completions

4. 新建知识库配置方案

新建一个知识库的配置方案，此刻就能选出我们前期新建的向量算法，完成后保存即可。

路径：【AI 服务云】-【Agent 平台】-【知识库配置方案】



按照下图所示，配置“知识库配置方案”

知识库配置方案

方案编码* 001 方案名称* 硅基流动-向量模型

方案描述 请描述该方案的使用场景。

数据预处理配置

检索策略 ☐ 向量检索 ☐ 全文检索

QA向量范围 ② ☒ Q ☒ Q&A

分块策略配置 向量服务接口创建后不可变更

向量服务接口* BAAI/BGE-M3-Embedding

分块长度* 350 分块重复长度* 0

分隔符 中文句号；英文句号 保留分隔符 ☐

知识库配置方案列表

新增 删除 刷新 关闭


已选1条，共4条

☐	#	方案编码	方案名称	方案描述	修改时间
☐	1	knlscheme_0305	金蝶自建向量服务	金蝶自建向量模型，通过API提供高效、精准的数据分析与处理服务	2025-09-08 17:24:38
☐	2	BAAI	Young创建向量服务	向量服务接口	2025-05-14 08:35:33
☐	3	BAIDU_ERNIE_BOT	百度智能云向量服务	百度智能云向量服务	2025-05-14 16:12:15
☒	4	001	硅基流动-向量模型		2025-09-08 19:27:09

5. 新建知识库

新建一个知识库，配置方案选择上一步新建的方案。

在【知识库】—【创建知识库】一点击左边咱们配置的知识库，填写（知识库名称），点击【创建】。



知识库创建

配置方案

硅基流动-向量模型

方案描述

金蝶自建向量服务

金蝶自建向量模型，通过API提供高效...

百度智能云向量服务

百度智能云向量服务

Young创建向量服务

向量服务接口

基础信息

知识库名称*

案例知识库

知识库编码*

alzsk

知识库描述

案例知识库

所属分组

知识库分组

授权

☒ 启用授权

管理员 ②

张三

选择角色

内容编辑 ②

选择人员

选择角色

内容审核 ②

选择人员

选择角色

浏览权限 ②

选择人员

选择角色

取消

创建

点击创建的知识库，进入知识库的管理（可导入文档等资料）

知识库列表

常用条件过滤

业务组织：环宇科技集团

使用状态：可用

搜索编码/名称

创建知识库

删除

禁用

刷新

进入旧版

退出

搜索名称

全选已选1条，共8条

共1页 第1页

全部

个人资料库

公司知识库

开发知识库

通用知识库

演示知识库

案例知识库

alzsk

案例知识库

0 0

授权 ...

test

test

test

3 0

授权 ...

首先新增节点：

案例知识库

常用

新增

业务组织：环宇科技集团

搜索知识编

搜索名称

新增节点

全部

文档

问答对

新增

删除

提交

审核

导入知识

更多

刷新

退出

#

知识编码

知识名称

状态

导入状态

导入信息

修改人

知识目录

20250908

创建目录 数据公开范围配置

可见范围 公开

创建一级目录

取消

确定

可以根据目录进行知识库新增。

案例知识库 常用条件过滤 业务组织: 环宇科技集团

搜索名称

文档 问答对

新增 删除 提交 审核 导入知识 更多 刷新 退出

20250908 (公开)

知识编码 知识名称 状态 导入状态 导入信息 修改人 修改时间

新增 删除 保存 保存并新增 提交 退出

基本信息

知识编码* 001 知识名称* 测试 分块算法 通用文件 状态 暂存 分组* 20250908 创建组织 环宇科技集团 失效时间

知识内容 分块信息 问答对

上传文件 全部下载

支持txt、pdf、docx、xls、xlsx格式

AI助手智能填单.docx (1.85MB) 张三 2025-09-08 备注

任务目的 用户给苍穹助手发送一个出差申请，包括出差时间、出发地、目的地、出差天数、事由、乘坐交通工具等信息，让苍穹助手为我们生成出差申请单据。生成之后，返回链接给我们，当我们点击链接，自动跳转到刚才添加的界面进行操作。

自动填单实现流程 设计提示词，将用户的输入(包括出差时间、出发地、目的地、出差天数、事由、乘坐交通工具等信息)转换成json格式字符串 编写插件，将json信息填入“出差申请单”，然后生成对应的链接。

任务目的 用户给苍穹助手发送一个出差申请，包括出差时间、出发地、目的地、出差天数、自动填单实现流程 设计提示词，将用户的输入(包括出差时间、出发地、目的地、出差天数、事由、编写插件，将json信息填入“出差申请单”，然后生成对应的链接。 将生成的“出差申请单”链接发送给消息节点(超链接形式)，生成出差申请单据整合成自动填单助手 准备工作

单击“保存”按钮，生成分块信息。

新增删除保存保存并新增提交退出

基本信息

知识编码*001

知识名称*测试

分块算法②通用文件

状态暂存

分组*20250908

创建组织环宇科技集团

失效时间②

知识内容分块信息问答对

共28个分块

1

任务目的

用户给苍穹助手发送一个出差申请，包括出差时间、出发地、目的地、出差天数、事由、乘坐交通工具等信息，让苍穹助手为我们生成出差申请单据。生成之后，返回链接给我们，当我们点击链接，自动跳转到刚才添加的界面进行操作。

自动填单实现流程

设计提示词，将用户的输入(包括出差时间、出发地、目的地、出差天数、事由、乘坐交通工具等信息)转成json格式字符串

编写插件，将json信息填入“出差申请单”，然后生成对应的链接。

将生成的“出差申请单”链接发送给消息节点（超链接形式），生成出差申请单链接。

整合成自动填单助手

准备工作

- 1、新建出差申请单
- 2、配置编码规则
- 3、配置算法服务和算法实例

实现步骤

步骤一：设计提示词

这一步的目的是根据用户的输入提炼出“出差申请单”的相关JSON信息

返回到列表界面，提交之后再进行审核。使其状态变为“已审核”，“导入状态”变为“已完成”。

案例知识库常用条件过滤业务组织：环宇科技集团搜索知识编码/知识名称展开过滤

文档问答对

新增删除提交审核导入知识更多刷新退出

已全选1条

#	知识编码	知识名称	状态	导入状态	导入信息	修改人	修改时间	创建人	创建时间	失效时间
1	001	测试	已审核	已完成		张三	2025-09-08 19:36:38	张三	2025-09-08 19:32:39	

也可以根据目录进行导入知识库，支持 PDF、DOCX、TXT 等多种格式，导入知识后先提交，然后进行审核即可完成知识的入库。若导入失败，可以查看导入信息，有日志可以查看。



导入知识后，待知识被知识分块后，在列表中，即可单击【提交】—【审核】。



注意：若新建知识库失败，请检查向量数据库服务是否正常启动。

```
连接主机...
连接主机成功
Last failed login: Mon Sep  8 17:18:54 CST 2025 from 192.168.195.1 on ssh:notty
There was 1 failed login attempt since the last successful login.
Last login: Fri Sep  5 13:41:00 2025
[root@localhost ~]# ls
anaconda-ks.cfg
[root@localhost ~]#
[root@localhost ~]#
[root@localhost ~]# systemctl start docker
[root@localhost ~]# cd /milvus
[root@localhost milvus]# docker-compose -f docker-compose.yml up -d
Starting milvus-etcd ...
Starting milvus-minio ... done
Starting milvus-standalone ... done
[root@localhost milvus]# docker ps
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS
9764c5060df8   milvusdb/milvus:v2.2.3              "/tini -- milvus run..." 3 months ago   Up 22 seconds
->9091/tcp, :::9091->9091/tcp, 0.0.0.0:19530->19530/tcp, :::19530->19530/tcp   milvus-standalone
b495d40f5916   minio/minio:RELEASE.2022-03-17T06-34-49Z "/usr/bin/docker-ent..." 3 months ago   Up 24 seconds (health: starting)
-9001->9000-9001/tcp, :::9000-9001->9000-9001/tcp                               milvus-minio
a6c28a61b084   quay.io/coreos/etcd:v3.5.5          "etcd -advertise-cli..." 3 months ago   Up 24 seconds
p                                              milvus-etcd
[root@localhost milvus]# ps -ef | grep milvus
root      2773    2740    0 17:20 ?        00:00:00 /tini -- milvus run standalone
root      2812    2773    0 17:20 ?        00:00:42 milvus run standalone
root      5825    1254    0 17:23 pts/0    00:00:00 grep --color=auto milvus
[root@localhost milvus]#
```

且 MC 中是否正常配置向量数据库且连接正常。

租户列表

向量数据库管理列表

集群管理列表

向量数据库管理

新增

删除

分配

刷新

退出

已全选1条

☒	编码	名称	用户名	服务器地址	备注	创建时间	修改时间	已分配租户
☒	01	向量数据库	root	192.168.195.129:19530		2025-05-13 21:10:05	2025-09-08 17:22:34	ierp

连接成功!

向量数据库管理列表

集群管理列表

向量数据库管理

编码*

名称*

01

向量数据库

服务器地址*

192.168.195.129:19530

用户名*

密码*

root

备注

退出

测试连接

保存